

# Implicit weak adversarial networks to solve stochastic partial differential equations

Кафедра интеллектуального анализа данных

Доклад подготовил: Папай Иван

# Постановка задачи: Эллиптические PDE

## Общая форма краевой задачи

Найти  $u : \Omega \subset \mathbb{R}^d \rightarrow \mathbb{R}$  такую, что:

$$\begin{cases} -\sum_{i=1}^d \partial_i \left( \sum_{j=1}^d a_{ij} \partial_j u \right) + \sum_{i=1}^d b_i \partial_i u + cu = f, & \text{в } \Omega \\ u = g \text{ (Дирихле)} \quad \text{или} \quad \frac{\partial u}{\partial \vec{n}} = g \text{ (Нейман)}, & \text{на } \partial\Omega \end{cases}$$

## Условие сильной эллиптичности

Существует  $\theta > 0$  такое, что:

$$\xi^\top A(x) \xi \geq \theta |\xi|^2 \quad \forall \xi \in \mathbb{R}^d, \quad x \in \Omega \text{ п.в.}$$

где  $A(x) = [a_{ij}(x)] \in \mathbb{R}^{d \times d}$  симметрична.

# Параболические PDE

## Начально-краевая задача

Найти  $u : \Omega \times [0, T] \rightarrow \mathbb{R}$  такую, что:

$$\begin{cases} u_t - \sum_{i=1}^d \partial_i \left( \sum_{j=1}^d a_{ij} \partial_j u \right) + \sum_{i=1}^d b_i \partial_i u + cu = f, & \text{в } \Omega \times [0, T] \\ \text{Граничные условия на } \partial\Omega \times [0, T] \\ u(x, 0) = h(x), & \text{в } \Omega \end{cases}$$

## Операторная форма

$$u_t + L(x, t; u) = f$$

где

$$L(x, t; u) = -\nabla \cdot (A \nabla u) + \mathbf{b} \cdot \nabla u + cu$$

# Слабая формулировка PDE

## Общий вид эллиптического PDE

$$-\nabla \cdot (A \nabla u) + \mathbf{b} \cdot \nabla u + cu = f \quad \text{в } \Omega$$

## Слабая форма

Найти  $u \in H^1(\Omega)$  такую, что:

$$\langle A[u], \varphi \rangle = 0 \quad \forall \varphi \in H_0^1(\Omega)$$

где

$$\langle A[u], \varphi \rangle = \int_{\Omega} (A \nabla u \cdot \nabla \varphi + \mathbf{b} \varphi \cdot \nabla u + cu \varphi - f \varphi) dx$$

# Ключевая идея WAN

## Минимаксная переформулировка

$$\|A[u]\|_{op} = \sup_{\varphi \neq 0} \frac{|\langle A[u], \varphi \rangle|}{\|\varphi\|_2}$$

$$u - \text{решение} \Leftrightarrow \|A[u]\|_{op} = 0$$

## Задача оптимизации

$$\min_u \max_{\varphi} \frac{|\langle A[u], \varphi \rangle|^2}{\|\varphi\|_2^2}$$

- ▶  $\min_u$ : найти решение PDE
- ▶  $\max_{\varphi}$ : найти "наихудшую" тестовую функцию

# Функция потерь и обучение

## Общая функция потерь

$$L(\theta, \eta) = \underbrace{\log |\langle A[u_\theta], \varphi_\eta \rangle|^2 - \log \|\varphi_\eta\|_2^2}_{\text{Внутренняя область}} + \alpha \underbrace{L_{\text{bdry}}(\theta)}_{\text{Граница}}$$

## Adversarial обучение


1. Фиксируем  $u_\theta$ , обновляем  $\varphi_\eta$ :

$$\eta \leftarrow \eta + \tau_\eta \nabla_\eta L(\theta, \eta)$$

2. Фиксируем  $\varphi_\eta$ , обновляем  $u_\theta$ :

$$\theta \leftarrow \theta - \tau_\theta \nabla_\theta L(\theta, \eta)$$

# Архитектура WAN: Две соревнующиеся сети



## Primal Network $u_\theta$

- ▶ Аппроксимирует решение PDE
- ▶ Минимизирует остаток
- ▶ Выход:  $u_\theta(x)$

## Test Network $\varphi_\eta$

- ▶ Аппроксимирует тестовую функцию
- ▶ Максимизирует остаток
- ▶ Выход:  $\varphi_\eta(x)$

# Параболические PDE: Уравнение теплопроводности

## Постановка задачи

$$\begin{cases} \frac{\partial u}{\partial t} = \nabla \cdot (D \nabla u) + f(x, t), & (x, t) \in \Omega \times [0, T] \\ u(x, 0) = u_0(x), & x \in \Omega \\ u = g \text{ на } \partial\Omega \end{cases}$$

## Слабая форма с интегрированием по времени

$$\begin{aligned} \langle A[u], \varphi \rangle = & \int_{\Omega} (u_T \varphi_T - u_0 \varphi_0) dx - \int_0^T \int_{\Omega} u \partial_t \varphi dx dt + \\ & + \int_0^T \int_{\Omega} D \nabla u \cdot \nabla \varphi dx dt \end{aligned}$$




# Сравнение архитектур: WAN, IWAN, XWAN

Параметр	WAN	IWAN	XWAN
Активации	ReLU/tanh	<b>SIREN (sin)</b>	Neural ODE
Производные	Кусочно-гладкие	<b>Аналитические</b>	Точные (ODE)
Скорость	Быстрая	Средняя	<b>Оч. медл.</b>
Сходимость	Медл. (гладк.)	<b>Быстр. (гладк.)</b>	Теор. идеал.
Память	Малая	Малая	<b>Огромная</b>
Практичность	<b>Высокая</b>	<b>Высокая</b>	Низкая

## Подходы по моделированию primal network

- ▶ **IWAN** (SIREN): SIREN-Block
- ▶ **XWAN**: XNode-Block
- ▶ **WAN**: DNN

# Сравнение WAN и IWAN



# Применение к диффузионным моделям

## Связь с уравнением Фоккера-Планка

Диффузионный процесс:

$$dx_t = f(x_t, t)dt + g(t)dw_t$$

Его плотность  $p(x, t)$  удовлетворяет:

$$\frac{\partial p}{\partial t} = -\nabla \cdot (fp) + \frac{1}{2}g^2\Delta p$$

## WAN для обучения диффузионных моделей

- ▶ Параметризация:  $p_\theta(x, t)$  или  $s_\theta(x, t) = \nabla \log p_\theta$
- ▶ Обучение через слабую форму Фоккера-Планка
- ▶ Преимущество: Не нужны сэмплы из процесса

## Основные свойства WAN

- ▶ **Высокие размерности:**  $d \sim 100$  и более
- ▶ **Физическая интерпретация:** Слабая форма

## Что предлагается

- ▶ **IWAN:** Теория SIREN для PDE + доказательство сходимости
- ▶ **Связь:** Weak PDE solvers  $\leftrightarrow$  Diffusion models
- ▶ **Приложения:** Генеративное моделирование через PDE